

BAB III


METODOLOGI PENELITIAN

Metodologi penelitian merupakan pedoman operasional yang menjabarkan langkah-langkah sistematis dalam memecahkan masalah penelitian untuk mencapai tujuan yang telah ditetapkan. Mengingat penelitian ini bertujuan untuk menghasilkan produk teknologi pendidikan berupa aplikasi cerita anak berbasis *Generative AI* yang teruji validitas dan efektivitasnya, maka metode yang digunakan harus mampu menjembatani kesenjangan antara desain pedagogis dan rekayasa perangkat lunak. Bab ini akan menguraikan secara rinci mengenai desain penelitian, prosedur pengembangan sistem, subjek penelitian, instrumen yang digunakan, serta teknik analisis data untuk memvalidasi kelayakan produk yang dikembangkan.

3.1 Desain Penelitian

Berdasarkan tujuan penelitian ini, yaitu untuk mengembangkan sistem aplikasi penciptaan cerita anak yang adaptif sebagai media penanaman moral, maka metode yang digunakan adalah *Research and Development (R&D)*. Metode Penelitian dan Pengembangan (R&D) didefinisikan sebagai metode penelitian yang digunakan untuk menghasilkan produk tertentu, serta menguji keefektifan produk tersebut (Sugiyono, 2013). Maka dalam penelitian ini, produk yang dihasilkan adalah aplikasi penciptaan cerita anak yang adaptif berbasis *Generative AI*.

Untuk menjamin kualitas produk yang dihasilkan, penelitian ini mengadopsi model pengembangan ADDIE. Model ADDIE merupakan pedoman yang dinamis dan fleksibel untuk membangun alat bantu kinerja dan pelatihan yang efektif (Aldoobie, 2015). Alasan utama pemilihan model ini adalah strukturnya yang generik namun sistematis, yang secara tradisional digunakan oleh perancang instruksional dan pengembang pelatihan untuk menciptakan pengalaman pembelajaran yang terukur. Model ini terdiri dari lima fase: *Analysis* (Analisis), *Design* (Desain), *Development* (Pengembangan), *Implementation* (Implementasi), dan *Evaluation* (Evaluasi) (Aldoobie, 2015). Alur tahapan model ADDIE yang digunakan dalam penelitian ini diilustrasikan pada Gambar 3.1.1 berikut:



*Gambar 3. 1 Model Pengembangan ADDIE
sumber: adaptasi dari (Aldoobie, 2015)*

Keunggulan model ini terletak pada integrasi evaluasi formatif di setiap tahapan, bukan hanya di akhir proses (Aldoobie, 2015). Hal ini sangat relevan dengan pengembangan sistem berbasis kecerdasan buatan, karena proses fine-tuning model bahasa memerlukan iterasi perbaikan berkelanjutan.

Berikut adalah uraian rinci penerapan kelima fase ADDIE yang disesuaikan dengan pengembangan aplikasi penciptaan cerita anak adaptif (Aldoobie, 2015):

1. Analisis (*Analysis*)

Fase analisis merupakan tahap klarifikasi masalah instruksional dan penentuan tujuan. Pada tahap ini, peneliti mengidentifikasi lingkungan pembelajaran serta pengetahuan dan keterampilan yang dimiliki oleh audiens atau pengguna saat ini. Pada tahap ini dilakukan analisis kebutuhan terhadap kesenjangan konten moral pada media digital anak saat ini dan menganalisis spesifikasi teknis infrastruktur AI yang dibutuhkan untuk menjalankan model Qwen 2.5 7B.

2. Desain (*Design*)

Fase desain berkaitan dengan perancangan tujuan pembelajaran, instrumen penilaian, latihan, konten, dan analisis materi pelajaran. Fase ini menuntut perencanaan yang sistematis dan spesifik. Pada tahap ini dilakukan perancangan arsitektur *prompt engineering* untuk memastikan output cerita sesuai dengan nilai moral, serta merancang antarmuka pengguna (*User*

Interface) aplikasi berbasis React Native yang ramah pengguna bagi orang tua.

3. Pengembangan (*Development*)

Fase pengembangan merupakan tahap pembuatan dan perakitan aset konten yang telah dirancang pada fase desain. Pada tahap ini, segala rancangan teoritis diubah menjadi bentuk fisik atau digital yang nyata. Aktivitas utama meliputi proses coding aplikasi, fine-tuning model AI menggunakan metode Unsloth, serta integrasi antara sistem backend (Python) dan frontend (*Mobile App*).

4. Implementasi (*Implementation*)

Tahap implementasi mencakup prosedur pelatihan bagi fasilitator dan pelajar (pengguna) untuk menggunakan produk yang dikembangkan. Tujuannya yaitu untuk memastikan bahwa produk dapat digunakan sesuai fungsinya di lingkungan nyata. Produk aplikasi diujicobakan kepada subjek penelitian, yaitu orang tua, untuk melihat bagaimana sistem bekerja dalam skenario penggunaan secara kasus nyata.

5. Evaluasi (*Evaluation*)

Fase evaluasi dibagi menjadi dua aspek yaitu evaluasi formatif yang hadir di setiap tahap proses ADDIE, dan evaluasi sumatif yang dilakukan pada akhir proses. Evaluasi sumatif biasanya melibatkan tes yang dirancang sesuai kriteria acuan domain terkait dan memberikan umpan balik dari pengguna. Evaluasi formatif dilakukan saat *debugging* kode dan pengujian respon AI per iterasi, sedangkan evaluasi sumatif dilakukan untuk mengukur efektivitas aplikasi dalam membantu orang tua untuk kontrol konten narasi anak berdasarkan nilai moral.

Dengan menggunakan kerangka kerja ADDIE, proses pengembangan aplikasi pada penelitian ini dapat dikontrol secara ketat kualitasnya, memastikan bahwa setiap fitur teknologi yang dibangun benar-benar menjawab kebutuhan pedagogis yang telah dianalisis sebelumnya.

3.2 Prosedur Penelitian (Alur ADDIE)

Prosedur penelitian ini mengacu pada model pengembangan ADDIE yang dilaksanakan secara sistematis dan iteratif. Setiap tahapan dirancang untuk

memastikan bahwa produk aplikasi yang dihasilkan tidak hanya berfungsi secara teknis, namun juga valid secara pedagogis dalam menjawab permasalahan *digital parenting*. Alur kerja pengembangan sistem ini dimulai dari analisis mendalam terhadap masalah dan kebutuhan, dilanjutkan dengan perancangan solusi, pengembangan teknis, implementasi kepada pengguna, hingga evaluasi akhir.

Secara rinci, prosedur operasional dalam penelitian ini diuraikan ke dalam lima tahapan utama sebagai berikut:

3.2.1 Tahap Analisis (*Analysis*)

Tahap analisis merupakan fondasi utama dalam penelitian pengembangan (R&D). Pada tahap ini, dilakukan investigasi menyeluruh untuk mendefinisikan kesenjangan (*gap*) antara kondisi ideal pengasuhan anak dengan realitas tantangan digital saat ini, serta menentukan spesifikasi teknologi yang layak (*feasible*) untuk diterapkan (Aldoobie, 2015). Analisis ini dibagi menjadi dua dimensi utama, yaitu analisis kebutuhan pedagogis dan analisis kelayakan teknologi.

1. Analisis Kebutuhan Pedagogis (*Needs Analysis*)

Analisis kebutuhan difokuskan pada urgensi intervensi moral bagi anak usia dini di tengah ekosistem digital yang didominasi algoritma. Berdasarkan studi literatur, ditemukan fakta bahwa lima tahun pertama kehidupan anak (*Golden Age*) merupakan periode kritis di mana arsitektur dasar otak yang mengatur emosi, perilaku sosial, dan moralitas sedang dibentuk secara pesat (Richmond et al., 2016). Kegagalan dalam memberikan stimulus moral yang tepat pada fase ini dapat berdampak jangka panjang pada perkembangan karakter anak.

Namun sayangnya, orang tua saat ini terhalang dengan fenomena "gelembung filter" (*filter bubble*) pada platform media sosial. Algoritma rekomendasi konten cenderung mengisolasi pengguna dalam lingkungan informasi yang homogen berdasarkan riwayat klik semata tanpa mempertimbangkan nilai-nilai edukasi dan keberagaman perspektif yang dibutuhkan anak (Pariser, 2011). Akibatnya, orang tua kehilangan kendali atas narasi yang dikonsumsi anak mereka.

Berdasarkan kesenjangan tersebut, ditetapkan kebutuhan fungsional aplikasi sebagai berikut:

- a) Aplikasi harus menempatkan orang tua sebagai pengendali utama (*gatekeeper*) konten cerita yang dikonsumsi anak berdasarkan nilai moralnya (Pariser, 2011).
- b) Cerita yang dihasilkan harus mampu berfungsi sebagai simulator sosial yang melatih respon moral anak (Gopnik, 2016).

Untuk memperjelas kesenjangan masalah yang mendasari pengembangan ini, disajikan analisis kesenjangan pada Tabel 3.1 berikut:

Tabel 3. 1 Analisis Kesenjangan Kebutuhan Pengasuhan Digital

Aspek	Kondisi Ideal (Harapan)	Realitas Saat Ini (Masalah)	Solusi yang Dikembangkan
Kontrol Narasi	Orang tua menyeleksi nilai moral yang sesuai untuk anak.	Algoritma platform (<i>filter bubble</i>) menentukan konten berdasarkan popularitas (Pariser, 2011).	Aplikasi dengan fitur input parameter moral spesifik oleh orang tua.
Stimulus Otak	Anak menerima cerita yang merangsang empati dan kognitif (Richmond et al., 2016).	Anak terpapar konten hiburan pasif yang minim nilai edukasi.	<i>Generative AI</i> yang menciptakan cerita adaptif sesuai konteks anak.
Interaksi	Terjalin ikatan (<i>bonding</i>) saat bercerita.	Terjadi <i>technoference</i> atau gangguan gawai yang memisahkan interaksi (Mcdaniel et al., 2019).	Aplikasi dirancang sebagai alat bantu <i>co-reading</i> (baca bersama).

2. Analisis Teknologi (*Technology Analysis*)

Setelah kebutuhan pedagogis teridentifikasi, dilakukan analisis teknis untuk menentukan arsitektur sistem yang mampu menjalankan kecerdasan buatan canggih pada infrastruktur dengan sumber daya terbatas. Tantangan utamanya adalah menjalankan *Large Language Model* (LLM) yang pada umumnya membutuhkan *server* GPU kelas atas. Berdasarkan tinjauan spesifikasi model terkini, penelitian ini menetapkan spesifikasi teknis sebagai berikut:

- a. **Model Bahasa (Base Model):** Dipilih model Qwen 2.5 7B. Model ini dipilih karena memiliki kemampuan *instruction following* yang superior dan performa multibahasa yang tinggi, sehingga mampu menghasilkan narasi Bahasa Indonesia yang alami dan koheren (Yang et al., 2025).
- b. **Teknik Optimasi (Efficiency):** Untuk mengatasi keterbatasan memori komputasi (*VRAM*), diterapkan teknik *Parameter-Efficient Fine-Tuning* (PEFT) menggunakan metode LoRA (*Low-Rank Adaptation*) dan kerangka kerja **Unsloth**. Penggunaan Unsloth terbukti mampu mempercepat proses pelatihan dan mengurangi konsumsi memori secara signifikan tanpa mengorbankan kualitas luaran model (Nguyen et al., 2025; Dettmers & May, 2023).
- c. **Antarmuka Pengguna (Frontend):** Pengembangan aplikasi *mobile* menggunakan kerangka kerja **React Native** dengan ekosistem **Expo**. Teknologi ini memungkinkan pembuatan aplikasi lintas platform (Android dan iOS) dengan performa *native* yang responsif dan efisiensi menggunakan satu basis code saja (Eisenman, 2017; Expo, 2026).

Spesifikasi teknis yang ditetapkan untuk pengembangan sistem dirangkum dalam Tabel 3.2 berikut:

Tabel 3. 2 Spesifikasi Teknis Pengembangan Sistem Aplikasi Penciptaan Cerita Anak Adaptif

Komponen Sistem	Teknologi Terpilih	Justifikasi Pemilihan (Referensi)
-----------------	--------------------	-----------------------------------

AI Model	Qwen 2.5 7B	Kemampuan <i>reasoning</i> dan <i>multilingual</i> (Indo) terbaik di kelas 7B parameter (Yang et al., 2025).
Training Framework	Unsloth + LoRA	Efisiensi memori hingga 70% dan pelatihan 2x lebih cepat (Nguyen et al., 2025).
Mobile Framework	React Native (Expo)	Performa <i>native</i> dan kemudahan <i>deployment</i> lintas platform (Eisenman, 2017).

3. Analisis Kebutuhan Sistem (*System Requirements*)

Berdasarkan analisis teknologi di atas, dikembangkan spesifikasi kebutuhan sistem untuk memastikan aplikasi dapat dibangun dan dijalankan secara optimal. Kebutuhan ini dibagi menjadi lingkungan pengembangan (*Development*) dan lingkungan produksi (*Production*):

a) Perangkat Keras (*Hardware Requirements*)

- o Pelatihan Model (Training): Proses *fine-tuning* LLM membutuhkan sumber daya komputasi tinggi. Penelitian ini akan memanfaatkan lingkungan *cloud* dengan GPU minimal tipe T4 (16GB VRAM) atau A100 yang tersedia pada platform seperti Google Colab atau Kaggle untuk menjalankan teknik efisiensi QLoRA (Dettmers & May, 2023).
- o Sisi Pengguna: Aplikasi target dirancang untuk berjalan pada perangkat seluler Android dengan spesifikasi minimum Android 8.0 (Oreo) dan RAM 2GB.

b) Perangkat Lunak (*Software Requirements*)

- o Framework AI: Menggunakan pustaka *Unsloth* untuk mempercepat proses *fine-tuning* dan mengurangi penggunaan memori GPU (Dettmers & May, 2023).
- o Backend API: Menggunakan bahasa pemrograman Python dengan kerangka kerja Flask untuk membangun API yang menjembatani aplikasi dengan model AI (Grinberg & O'Reilly, 2014).

- Frontend Mobile: Menggunakan React Native dengan Expo untuk pengembangan antarmuka lintas platform yang efisien (Eisenman, 2017; Expo, 2026).
- Database: Menggunakan Firebase untuk manajemen autentikasi pengguna dan penyimpanan data cerita secara *real-time*.

Spesifikasi teknis pengembangan sistem dirangkum dalam Tabel 3.3 berikut:

Tabel 3. 3 Spesifikasi Teknis Pengembangan Sistem

Komponen Sistem	Teknologi / Spesifikasi	Fungsi & Justifikasi Pemilihan
Model AI (Brain)	Qwen 2.5 7B (Instruct)	Sebagai mesin utama pembangkit cerita. Dipilih karena kemampuan multibahasa (khususnya Bahasa Indonesia) dan <i>instruction following</i> yang superior dibandingkan model sekelasnya (Yang et al., 2025).
Framework Pelatihan	Unsloth + LoRA	Digunakan untuk proses <i>fine-tuning</i> . Metode <i>Low-Rank Adaptation</i> (LoRA) memungkinkan efisiensi memori dengan membekukan bobot model pra-latih (Nguyen et al., 2025). Implementasi melalui Unsloth mempercepat pelatihan hingga 2x lipat dan mengurangi penggunaan VRAM hingga 70% melalui optimasi kernel manual (Han & Han, 2023), memungkinkan pelatihan dilakukan pada GPU T4.
Backend API	Python (Flask)	Berfungsi sebagai jembatan (<i>gateway</i>) yang menghubungkan aplikasi seluler dengan model AI. Flask dipilih karena ringan dan kompatibel dengan ekosistem AI Python (Grinberg & O'Reilly, 2014).

Frontend (Aplikasi)	React Native (Expo)	Kerangka kerja untuk membangun antarmuka aplikasi Android. Memungkinkan pengembangan lintas platform dengan satu basis kode JavaScript yang efisien (Eisenman, 2017). Penggunaan Expo menyederhanakan siklus pengembangan dan akses ke fitur <i>native</i> perangkat (Expo, 2026).
Database	Firebase (Firestore & Auth)	Layanan <i>cloud</i> untuk menyimpan data pengguna dan riwayat cerita. Dipilih karena kemampuan sinkronisasi data <i>real-time</i> dan kemudahan integrasi autentikasi pengguna yang aman tanpa perlu mengelola server fisik (Google Developers, 2026).

Hasil dari tahap analisis ini selanjutnya menjadi acuan dasar (*blueprint*) untuk melangkah ke tahap selanjutnya, yaitu tahap Desain (*Design*), yaitu tahap arsitektur sistem dan rancangan antarmuka akan dibuat secara rinci.

3.2.2 Tahap Desain (Design)


Tahap desain merupakan fase krusial di mana hasil analisis kebutuhan ditransformasikan menjadi spesifikasi teknis yang siap dikembangkan. Pada tahap ini, perancangan dilakukan secara komprehensif mencakup arsitektur kecerdasan buatan, persiapan data, skenario pelatihan, hingga antarmuka pengguna, untuk memastikan sistem dapat bekerja secara integratif.

1. Perancangan Arsitektur AI (*Model Architecture*)

Perancangan arsitektur AI berfokus pada pemilihan model dasar dan skema integrasi sistem. Penelitian ini menetapkan penggunaan model Qwen 2.5 7B sebagai mesin utama pembangkit cerita. Pemilihan ini didasarkan pada laporan teknis yang menunjukkan bahwa Qwen 2.5 memiliki performa *coding* dan matematika yang kompetitif, serta kemampuan multibahasa yang superior dibandingkan model seukurannya (Yang et al., 2025).

Keunggulan ini sangat krusial untuk menghasilkan narasi Bahasa Indonesia yang alami dan koheren.

Secara arsitektural, sistem dirancang dengan skema *client-server* yang memisahkan logika antarmuka pengguna dengan logika komputasi berat AI. Alur komunikasi data antarkomponen arsitektur tersebut diilustrasikan pada Gambar 3.2 berikut :



Gambar 3. 2 Arsitektur Integrasi Sistem


Berdasarkan Gambar 3.2 di atas, mekanisme kerja sistem dirancang sebagai berikut:

- Sisi Klien (Android App): Aplikasi bertindak sebagai antarmuka depan (*frontend*) yang mengumpulkan input pengguna berupa tema dan nilai moral. Data ini dikemas dan dikirimkan melalui protokol *HTTP Request* yang aman.
- Sisi Server (Python API): Server berbasis Flask menerima permintaan tersebut. Di sini, input pengguna dikonversi menjadi *prompt* terstruktur sesuai *template* yang telah dirancang.
- Inferensi AI: *Prompt* dikirim ke model AI (Qwen 2.5) untuk diproses. Model akan menghasilkan narasi cerita yang relevan.
- Respons Data (JSON): Teks cerita hasil generasi dikirimkan kembali ke aplikasi Android dalam format JSON (*JavaScript Object Notation*) agar mudah diurai (*parsing*) dan ditampilkan kepada pengguna.

2. Perancangan Dataset (*Dataset Preparation*)

Kualitas luaran *Generative AI* sangat bergantung pada kualitas data pelatihannya, sesuai dengan prinsip "*Less Is More for Alignment*" yang menyatakan bahwa sejumlah kecil data berkualitas tinggi dapat

mengalahkan data besar yang berkualitas rendah (Zhou et al., 2023). Oleh karena itu, dataset dirancang khusus untuk memetakan variabel input spesifik menjadi narasi utuh. Proses penyiapan data ini dilakukan secara bertahap mulai dari pengumpulan hingga validasi, sebagaimana diilustrasikan pada Gambar 3.3 dibawah.



Gambar 3. 3 Flow Chart Proses Penyiapan Data

Berdasarkan gambar 3.2.1 di atas, data dikurasi dari cerita domain publik dan *scraping* web, kemudian menggunakan *AI Assisted* untuk proses *labelling*, setelah itu data divalidasi manual dan diformat ulang. Data yang telah diformat ulang akan disusun dalam format **JSONL** (*JSON Lines*), yang merupakan standar industri untuk pelatihan model bahasa karena efisiensinya dalam menangani data teks berskala besar. Skema pasangan data dirancang sebagai berikut:


- **Input:** Kombinasi instruksi sistem, tema cerita (misal: "Petualangan, Dunia Hewan"), dan nilai moral (misal: "Kejujuran, Rasa Hormat").
- **Output:** Teks cerita anak lengkap yang mengandung unsur tema dan moral tersebut.

Pendekatan ini mengadopsi konsep *instruction tuning*, yaitu model dilatih untuk menyelaraskan diri dengan intensi pengguna melalui contoh-contoh instruksi yang eksplisit (Ouyang et al., 2022). Dataset ini dikurasi dari cerita domain publik yang kemudian divalidasi dan diformat ulang agar sesuai dengan struktur instruksi (*instruction tuning*) model.

3. Perancangan Skenario Fine-Tuning

Mengingat keterbatasan sumber daya komputasi, penelitian ini tidak melatih model dari awal (*pre-training*), melainkan menerapkan teknik *Parameter-Efficient Fine-Tuning* (PEFT). Metode spesifik yang dipilih adalah QLoRA

(*Quantized Low-Rank Adaptation*). QLora merupakan teknik yang memungkinkan proses *fine-tuning* model sebesar 7 Miliar parameter dilakukan pada GPU memori terbatas dengan mengkuantisasi *weight* model dasar untuk menghemat memori GPU, namun tetap mempertahankan performa yang setara dengan *full fine-tuning* (Dettmers & May, 2023). Metode ini telah terbukti efektif dalam survei terbaru mengenai adaptasi model bahasa besar (Zhao et al., 2025). Alur lengkap proses pelatihan model diilustrasikan pada Gambar 3.4 berikut.



Gambar 3. 4 FlowChart Proses Pelatihan Model

Berdasarkan ilustrasi alur pada Gambar 3.4, proses pengembangan dimulai dengan inisialisasi model dasar Qwen 2.5 7B kemudian menjalani tahap *fine-tuning* menggunakan dataset cerita anak untuk menanamkan pemahaman konteks moral. Model yang sudah divalidasi selanjutnya diunggah ke repositori *Hugging Face* guna memfasilitasi manajemen versi dan aksesibilitas. Rangkaian ini berlanjut ke tahap *deployment* yang mencakup konfigurasi infrastruktur *cloud* dan pengembangan *backend* API berbasis Python, serta diakhiri dengan optimasi *prompt engineering* untuk memastikan respon model presisi dan siap diintegrasikan (*API ready for integration*) dengan antarmuka aplikasi pengguna.

Pelatihan direncanakan akan dilaksanakan menggunakan infrastruktur *cloud* (seperti Kaggle/Colab) dengan dukungan GPU T4 x2 (poin d Anda masuk sini). Untuk mengakomodasi beban komputasi pada spesifikasi tersebut, ditetapkan konfigurasi *hyperparameters* awal sebagaimana dirinci pada Tabel 3.4. Konfigurasi ini dirancang berdasarkan praktik terbaik (*best practices*) untuk menyeimbangkan efisiensi memori dan stabilitas konvergensi model.

Tabel 3. 4 Rancangan Hyperparameter Fine-Tuning dan Landasan Teoritis Penetapan Nilai

Parameter	Nilai Konfigurasi	Dasar Teori & Referensi
Metode Kuantisasi	4-bit NormalFloat (NF4)	Standar QLoRA untuk mengurangi penggunaan VRAM hingga 50% tanpa degradasi akurasi signifikan (Dettmers & May, 2023).
LoRA Rank (r)	16	Rank 16 memberikan keseimbangan optimal antara jumlah parameter yang dilatih dan kemampuan adaptasi model pada tugas spesifik (Zhao et al., 2025).
LoRA Alpha	16	Faktor penskalaan (<i>scaling factor</i>) yang biasanya diset sama dengan nilai Rank untuk menstabilkan pembaruan <i>weight</i> (Zhao et al., 2025).
Learning Rate	2×10^{-4}	Laju pembelajaran standar untuk QLoRA. Nilai ini cukup kecil untuk mencegah kerusakan pada bobot <i>pre-trained</i> (<i>catastrophic forgetting</i>) namun cukup besar untuk konvergensi (Dettmers & May, 2023).
Batch Size	4 (per device)	Disesuaikan dengan kapasitas memori GPU T4 (16GB). Ukuran <i>batch</i> yang terlalu besar akan menyebabkan <i>Out of Memory</i> (OOM).
Gradient Accumulation	4 steps	Mengakumulasi gradien dari 4 <i>batch</i> kecil untuk mensimulasikan <i>Effective Batch Size</i> sebesar 16, guna

		menstabilkan <i>stochastic gradient descent</i> (Goyal et al., 2018)
Epoch	1 - 3	Jumlah iterasi dibatasi maksimal 3 kali. Pelatihan berlebih pada dataset kecil berisiko tinggi menyebabkan <i>overfitting</i> (Goodfellow et al., 2016)
Optimizer	AdamW (paged)	Varian Adam dengan <i>weight decay</i> yang dioptimalkan untuk manajemen memori pada model besar (Dettmers & May, 2023).
Max Sequence Length	1024 tokens	Dibatasi untuk efisiensi, mengingat target cerita anak berkisar antara 300-750 kata (sesuai batasan proposal).

4. Perancangan Prompt (*Prompt Engineering*)

Selain *fine-tuning*, kualitas interaksi dengan model sangat ditentukan oleh perancangan *prompt*. Penelitian ini memanfaatkan kemampuan *Zero-Shot Learning* dari model bahasa yang telah di-*fine-tune*, di mana model dapat mengerjakan tugas baru hanya dengan instruksi deskriptif tanpa contoh (Wei et al., 2022). Model Qwen memiliki kapabilitas *instruction following* yang tinggi, memungkinkannya memahami perintah kompleks dan bernalar sesuai konteks (Wang et al., 2024). Oleh karena itu, penelitian ini menggunakan format *template* prompt terstruktur (ChatML). Berikut adalah rancangan *template* prompt utama:

```
<|im_start|>system
Kamu adalah penulis cerita anak profesional Indonesia
yang ahli dalam menyisipkan pesan moral.<|im_end|>
<|im_start|>user
Tolong buat cerita anak dengan tema '{theme_value}'
yang mengajarkan nilai moral '{moral_value}'. Buat
dengan maksimal {word_value} kata. Buat tanpa
judul.<|im_end|>
```


```
<|im_start|>assistant
```

Struktur ini dirancang dengan instruksi langsung (*direct instruction*) untuk meminimalkan ambiguitas dan menjaga konsistensi luaran moral cerita karena model Qwen telah dilatih untuk menyelaraskan diri dengan intensi pengguna, sehingga instruksi yang eksplisit dan terstruktur akan menghasilkan luaran yang lebih akurat dan aman (Brown et al., 2020; Yang et al., 2024).

5. Perancangan Aplikasi (UI/UX)

Perancangan antarmuka aplikasi difokuskan pada kemudahan penggunaan (*usability*) bagi orang tua, yang merupakan faktor kunci dalam penerimaan teknologi (Brooke, 2020). Aplikasi dikembangkan menggunakan kerangka kerja React Native dengan ekosistem Expo. Pemilihan React Native didasarkan pada kemampuannya untuk membangun aplikasi lintas platform (*cross-platform*) dengan performa yang mendekati aplikasi *native*, serta efisiensi pengembangan (Eisenman, 2017; Zarichuk, 2023). Selain itu, penggunaan Expo mempermudah proses pengujian dan *deployment* aplikasi pada berbagai perangkat (Expo, 2026).

- a) Siklus pengembangan aplikasi dirancang untuk mengintegrasikan desain antarmuka, logika frontend, dan koneksi API sebagaimana digambarkan pada Gambar 3.5. Proses dimulai dengan perancangan antarmuka pengguna (*User Interface*) menggunakan Figma, yang kemudian ditranslasikan menjadi kode program menggunakan kerangka kerja React Native dan Expo untuk memastikan kompatibilitas lintas platform. Tahap krusial dalam alur ini yaitu integrasi API python dengan aplikasi dengan *framework* Flask. Pada titik ini, sistem melakukan validasi koneksi melalui gerbang logika "*API Connection Success?*". Jika koneksi gagal (*Error*), alur kerja masuk ke prosedur penanganan kesalahan (*Handle API Errors*) dan perbaikan kode (*Fixing*) sebelum mencoba integrasi ulang. Sebaliknya, jika koneksi berhasil (*Success*), aplikasi akan menampilkan cerita yang dihasilkan kepada pengguna, menandakan bahwa aplikasi telah stabil dan siap digunakan.




Gambar 3. 5 FlowChart Proses Pengembangan Aplikasi

b) Desain interaksi sistem aplikasi dirancang untuk memfasilitasi peran ganda antara pengawasan orang tua dan pengalaman literasi anak. Seperti divisualkan pada Gambar 3.6, sistem membagi aktor menjadi dua entitas utama dengan hak akses yang terbagi secara tegas: Supervisor (Orang Tua/Wali) dan Pengguna (Anak Usia Dini).

- Peran Supervisor yaitu memegang kendali penuh atas manajemen konten dalam sistem. Setelah melewati proses otentikasi (*Login*), Supervisor memiliki akses eksklusif ke fungsi krusial yang ditandai dengan relasi <<Include>>, yaitu "Generate Cerita" dan "Personalisasi Cerita". Hal ini menegaskan bahwa proses penciptaan konten tidak dapat dilakukan tanpa otentikasi yang valid. Selain itu, fitur "Generate Cerita Suara" diposisikan sebagai relasi <<Extend>>, yang berarti fitur ini adalah opsi tambahan yang dapat diaktifkan oleh orang tua untuk memperkaya narasi teks menjadi audio.
- Peran Pengguna Anak (Consumer) yaitu memiliki batasan akses yang ketat demi keamanan konten. Interaksi anak terpusat hanya pada "Pustaka Cerita", yang berfungsi sebagai wadah konten yang telah dikurasi oleh orang tua. Dari pustaka ini, anak dapat memilih aktivitas turunan melalui relasi <<Extend>>, yaitu "Baca Cerita" atau "Dengar Cerita".

Desain pemisahan aktor ini mengimplementasikan mekanisme *Human-in-the-Loop* secara visual, yaitu anak tidak memiliki akses langsung ke mesin generatif AI dan orang tua ikut berperan dalam proses. Arsitektur ini menjamin bahwa seluruh materi yang dikonsumsi anak di *Pustaka*

Cerita telah melewati filter pembuatan dan validasi moral oleh Supervisor, sesuai dengan prinsip *parental control* untuk mitigasi risiko paparan konten negatif.



Gambar 3. 6 Use Case Aplikasi

c) Logika operasional aplikasi dirancang untuk memandu pengguna melalui serangkaian keputusan terstruktur, mulai dari akses awal aplikasi hingga penyampaian konten. Seperti divisualisasikan pada Gambar 3.7, arsitektur alur kerja sistem terbagi menjadi dua percabangan utama berdasarkan peran pengguna: jalur Supervisor (Orang Tua) dan jalur User (Anak).

- **Validasi Peran dan Otentikasi**

Proses dimulai dengan inisialisasi aplikasi (*Application Opened*) yang langsung diikuti oleh gerbang logika pemilihan peran (*Select Role*). Jika pengguna memilih peran sebagai Supervisor, sistem mewajibkan proses otentikasi melalui Login atau Register. Mekanisme ini diterapkan untuk mengamankan hak akses pembuatan konten, memastikan bahwa hanya orang tua yang memiliki otoritas untuk memproduksi dan mengurus cerita.


- **Siklus Penciptaan dan Penyimpanan Cerita (Supervisor Flow)**

Inti dari logika sistem terletak pada fitur "*Generate Story*". Pada tahap ini, Supervisor memasukkan parameter kunci berupa Tema Cerita (*Story Theme*) dan Nilai Moral (*Moral Values*). Data ini

kemudian diproses oleh model AI untuk menghasilkan narasi (*Display Generated Story*). Diagram menunjukkan adanya fitur fleksibilitas di mana Supervisor dapat menyunting konten (*Edit Story Content*) sebelum menyimpannya ke basis data Firebase (*Store Story in Firebase*). Setelah itu, terdapat logika kondisional opsional untuk menghasilkan audio (*Generate Sound Story?*), untuk memicu fitur konversi teks-ke-suara.

- **Alur Konsumsi Konten (*User Flow*)**

Di sisi lain, alur untuk Anak (*User*) dirancang linier dan sederhana. Setelah memilih peran, pengguna langsung diarahkan ke *Story List* untuk memilih cerita yang tersedia. Sistem kemudian melakukan pengecekan logika otomatis (*Story has voice option?*) untuk menentukan apakah cerita akan disajikan dalam format teks saja (*Read Selected Story*) atau dilengkapi dengan audio (*Play Audio Story*). Pemisahan alur ini menjamin pengalaman pengguna yang aman dan bebas distraksi bagi anak.



Gambar 3. 7 Flowchart Sistem Apikasi

d) Desain visual aplikasi dirancang dengan pendekatan minimalis dan intuitif untuk meminimalkan beban kognitif pengguna. Gambar 3.8 menampilkan rancangan antarmuka *low-fidelity* yang memetakan kerangka navigasi utama, memprioritaskan pemisahan yang jelas antara area kontrol orang tua dan area interaksi anak. Berdasarkan rancangan tersebut, arsitektur antarmuka terbagi menjadi dua segmen fungsional:

- **Panel Kendali Supervisor:** Bagian ini dirancang padat fungsi untuk memfasilitasi peran orang tua sebagai ko-kreator. Terdapat formulir input parameter yang terstruktur, memungkinkan pengguna memilih "Genre" dan "Nilai Moral" secara spesifik sebelum melakukan proses *Generate*. Tata letak ini mendukung kontrol penuh orang tua terhadap muatan edukasi cerita anak, sesuai dengan prinsip pengasuhan digital yang aman.
- **Antarmuka Baca Anak:** Sebaliknya, tampilan untuk pengguna anak didesain dengan hierarki visual yang sederhana. Elemen navigasi yang kompleks dihilangkan, menyisakan fokus pada ilustrasi visual dan teks cerita yang dominan. Pendekatan desain ini bertujuan untuk menjaga atensi anak tetap pada narasi cerita tanpa terdistraksi oleh fitur teknis aplikasi.

Rancangan *wireframe* ini menjadi cetak biru (*blueprint*) tampilan aplikasi sebelum ditransformasikan menjadi antarmuka yang responsif menggunakan komponen *native* pada kerangka kerja React Native.

3.2.3 Tahap Pengembangan (Development)

Tahap pengembangan merupakan fase realisasi di mana seluruh rancangan desain ditransformasikan menjadi produk perangkat lunak yang fungsional. Pada tahap ini, aktivitas difokuskan pada tiga pilar utama: persiapan data instruksional, eksekusi pelatihan model kecerdasan buatan (*fine-tuning*), dan pengkodean aplikasi lintas platform.

1. Pengumpulan dan Pelabelan Data (*Data Preparation*)

Tahap persiapan data merupakan langkah awal untuk memastikan model AI memiliki basis pengetahuan yang relevan dengan konteks pendidikan karakter anak. Proses ini dilakukan melalui empat tahapan sistematis yaitu akuisisi data, pelabelan berbantuan AI (*LLM-assisted labeling*), penyeimbangan distribusi data (*data balancing*), dan pemformatan akhir.

a) Akuisisi Data (*Data Acquisition*)

Sumber data diperoleh melalui proses web crawling menggunakan *Application Programming Interface* (API) dari platform perpustakaan digital Let's Read (*The Asia Foundation*). Platform ini dipilih karena menyediakan repositori cerita anak berkualitas tinggi yang telah terkurasi secara budaya dan bahasa. Data mentah yang diunduh mencakup teks cerita, judul, dan metadata dasar lainnya seperti tema cerita. Selanjutnya, dilakukan proses pembersihan data (*data cleaning*) untuk menghapus karakter non-alfanumerik, simbol yang tidak relevan, serta cerita yang terlalu pendek atau tidak memiliki struktur narasi yang utuh.

b) Pelabelan Data Otomatis (*LLM-Assisted Labeling*)

Data mentah dari sumber asli Let's Read belum memiliki label spesifik terkait "Nilai Moral" yang dibutuhkan untuk instruksi fine-tuning, maka pada penelitian ini menerapkan metode pelabelan otomatis menggunakan *Large Language Model*. Model Qwen 2.5 7B digunakan sebagai agen analis untuk membaca setiap cerita dan mengekstraksi atribut metadata baru, yaitu nilai moral dominan yang terkandung di dalam cerita tersebut.

Pemilihan Qwen 2.5 7B didasarkan pada kemampuan penalarannya (*reasoning*) yang kuat dalam memahami konteks implisit dalam teks Bahasa Indonesia (Yang et al., 2025).

c) Penyeimbangan dan Augmentasi Data (*Data Balancing & Augmentation*)

Untuk mencegah bias model terhadap nilai moral tertentu akibat ketidakseimbangan kelas (*imbalanced data*) pada dataset asli, maka dilakukan teknik augmentasi data sintetis (*synthetic data generation*). Pada kelas nilai moral yang memiliki representasi data rendah (*minority class*), dilakukan pembangkitan cerita baru menggunakan model yang lebih besar, yaitu Qwen 2.5 14B. Model ini diinstruksikan untuk menulis cerita baru dengan tema dan nilai moral spesifik yang kurang terwakili, sehingga distribusi data menjadi seimbang. Pendekatan ini bertujuan untuk meningkatkan *robustness* model agar mampu menghasilkan narasi yang beragam untuk setiap kategori moral (Wang et al., 2024).

d) Pemformatan Data (*Data Formatting*)

Data yang telah bersih, terlabeli, dan seimbang kemudian dikompilasi ke dalam format JSONL (*JSON Lines*). Struktur data dirancang mengikuti format instruksi (*instruction tuning*) dengan pasangan "Instruksi - Respons". Format ini dipilih untuk memfasilitasi proses *Supervised Fine-Tuning* (SFT), yaitu kualitas data lebih diutamakan daripada kuantitas, mengacu pada prinsip "*Less Is More for Alignment*" yang menyebutkan bahwa dataset kecil namun berkualitas tinggi dapat menghasilkan performa *alignment* yang optimal (Zhou et al., 2023). Adapun struktur satu baris data JSONL yang digunakan dalam penelitian ini berikut:

```
{  
    "instruction": "Tolong Buatlah cerita anak  
dengan tema 'Perempuan Tangguh' yang  
mengajarkan nilai moral 'Kejujuran'. Buat  
dengan maksimal 200 kata. Buat tanpa judul",
```

```
"input": "",  
  "output": "Teman-temanku memanggil. Mereka  
mengajakku bermain bola..."  
}
```

2. Pengembangan Model AI (*Fine-Tuning Execution*)

Inti dari kecerdasan sistem ini dibangun dengan melakukan *fine-tuning* pada model Qwen 2.5 7B. Model ini dipilih karena arsitekturnya yang telah dioptimalkan untuk pemahaman instruksi dan kemampuan multibahasa yang superior (Yang et al., 2025). Untuk mengatasi keterbatasan sumber daya komputasi (GPU), proses pelatihan menerapkan teknik **QLoRA** (*Quantized Low-Rank Adaptation*). Secara spesifik, bobot model utama dibekukan dalam presisi 4-bit, sementara pelatihan difokuskan pada pembaruan parameter adaptor (LoRA) yang disisipkan pada modul atensi linier (*linear attention modules*) meliputi `q_proj`, `k_proj`, `v_proj`, dan `o_proj`. Pendekatan target modul yang komprehensif ini terbukti meningkatkan kemampuan generalisasi model dibandingkan hanya menargetkan sebagian lapisan saja, namun tetap menjaga efisiensi memori (Dettmers & May, 2023).

Efisiensi pelatihan dimaksimalkan menggunakan pustaka Unsloth yang dikombinasikan dengan pengoptimal AdamW 8-bit. Penggunaan optimizer 8-bit secara signifikan mereduksi jejak memori (*memory footprint*) saat proses *backpropagation*, sehingga dapat dilakukan pelatihan dengan *context window* yang lebih panjang pada perangkat keras terbatas (Nguyen et al., 2025). Sebelum pelatihan, dataset diformat menggunakan *Chat Template* standar Qwen untuk memastikan model mengenali struktur instruksi dan respons secara akurat.

3. Pengembangan Backend API (*Backend Development*)

Pengembangan sisi server (*backend*) dibangun menggunakan *framework* Python Flask. Flask dipilih karena arsitekturnya yang ringan (*micro-framework*) namun memiliki fleksibilitas tinggi untuk menangani permintaan HTTP dan integrasi dengan *libraries* kecerdasan buatan

(Grinberg & O'Reilly, 2014). Berdasarkan kebutuhan sistem terdapat tiga modul utama yang dikembangkan:

a) Modul Inferensi Model Backend

bertanggung jawab memuat model Qwen 2.5 7B beserta adaptor LoRA hasil *fine-tuning*. Untuk menjaga efisiensi memori pada lingkungan produksi dengan sumber daya terbatas, maka diterapkan mekanisme pemuatan model berbasis kuantisasi 4-bit (*4-bit loading*). Teknik ini terbukti mampu mereduksi kebutuhan memori GPU secara signifikan tanpa degradasi performa model yang drastis (Dettmers & May, 2023).

b) Manajemen Endpoint API

Sistem komunikasi data dirancang menggunakan arsitektur REST (*Representational State Transfer*) untuk menjamin interoperabilitas antara klien dan server (Hillar, 2016). Dikembangkan dua *endpoint* utama:

- */generate_story* (POST): Menerima input JSON berupa tema dan nilai moral dari aplikasi. Di dalam *endpoint* ini, sistem secara otomatis membungkus input pengguna ke dalam format *ChatML* standar sebelum dikirim ke model. Standardisasi format instruksi ini krusial untuk memastikan model dapat mengikuti perintah (*instruction following*) secara konsisten sesuai dengan pola data pelatihannya (Ouyang et al., 2022).
- */tts_generate* (POST): Menangani konversi teks menjadi audio, yaitu hasil audio disimpan sementara di server dan dikirimkan kembali ke klien dalam bentuk tautan berkas atau *byte stream*.

c) Eksposur Jaringan (*Network Tunneling*)

Untuk memfasilitasi komunikasi *real-time* antara aplikasi *mobile* dan server inferensi yang berjalan pada infrastruktur tertutup (*cloud notebook*), diimplementasikan teknik *secure tunneling* menggunakan Ngrok. Solusi ini memungkinkan pembuatan *public URL* yang aman (HTTPS) untuk mengekspos layanan web lokal ke internet tanpa memerlukan konfigurasi IP statis yang kompleks, yang umum

digunakan untuk mempercepat siklus pengembangan dan pengujian sistem terdistribusi (Hillar, 2016).

4. Pengembangan Aplikasi (*App Development*)

Pengembangan antarmuka untuk pengguna dilakukan menggunakan *framework* React Native dengan ekosistem Expo. Pendekatan ini memungkinkan pembuatan aplikasi *native* untuk Android menggunakan basis kode JavaScript yang efisien (Eisenman, 2017). Penggunaan Expo secara spesifik mempercepat siklus pengembangan melalui fitur-fitur seperti *Over-the-Air updates* dan kemudahan akses ke API perangkat (Expo, 2026). Arsitektur aplikasi dirancang dengan menerapkan prinsip pemisahan kepentingan (*separation of concerns*), yaitu komponen antarmuka (UI) dipisahkan dari logika bisnis dan komunikasi data (Eisenman, 2017; Grinberg & O'Reilly, 2014). Integrasi antara aplikasi *mobile* dan *backend server* dilakukan melalui pertukaran data berbasis RESTful API (Hillar, 2016). Berikut merupakan implementasi kode fungsi penciptaan cerita anak yang menangani pengiriman parameter personalisasi (moral, tema, dan estimasi kata) ke *endpoint* server:

```
const generateStory = async (selectedMoral,
selectedTheme, selectedWordCount) => {
  const apiUrl = `${BASE_URL}/generate`;

  try {
    const response = await fetch(apiUrl, {
      method: 'POST',
      headers: {
        'Content-Type': 'application/json',
      },
      body: JSON.stringify({
        moral: selectedMoral.label,
        theme: selectedTheme.label,
        word: selectedWordCount,
```

```

    }),
    });

    if (!response.ok) {
        throw new Error(`HTTP error! status:
        ${response.status}`);
    }

    const data = await response.json();
    return data;

    } catch (error) {
        console.error("Gagal      men-generate
cerita:", error);
        throw error;
    }
};

```

Implementasi kode di atas memanfaatkan pola pemrograman asinkron (async/await) yang berfungsi agar aplikasi ketika melakukan permintaan jaringan HTTP tidak memblokir antarmuka pengguna (*non-blocking UI*) (Eisenman, 2017; Haverbeke, 2007). Data input dari pengguna dikonversi menjadi format JSON (*JavaScript Object Notation*) sebelum dikirim, untuk memastikan interoperabilitas data yang konsisten dengan layanan *backend* Flask yang telah dibangun sebelumnya (Grinberg & O'Reilly, 2014; Hillar, 2016). Mekanisme penanganan kesalahan (*error handling*) juga diterapkan untuk menjaga stabilitas aplikasi apabila terjadi kegagalan jaringan (Eisenman, 2017).

3.2.4 Tahap Implementasi (Implementation)

Tahap implementasi merupakan fase transisi pada sistem yang telah dikembangkan dipersiapkan untuk selanjutnya digunakan di lingkungan nyata.

Fokus utama tahap ini yaitu penyebaran (*deployment*) model, integrasi sistem secara menyeluruh, dan pengujian fungsional awal.

1. ***Deployment Model AI***

Tahap deployment difokuskan pada distribusi model agar dapat diakses oleh layanan backend yang telah dibangun sebelumnya. Mengingat ukuran model bahasa besar yang masif, maka strategi *deployment* yang diterapkan yaitu arsitektur hibrida yang memisahkan media penyimpanan (*storage*) dengan lingkungan eksekusi (*compute*).

a) **Distribusi Repo Model (*Model Repository*)**

Alih-alih menyimpan model secara monolitik, sistem hanya mendistribusikan parameter adaptor QLoRA hasil fine-tuning ke repositori publik Hugging Face Hub. Pendekatan ini dipilih karena efisiensinya. Adaptor QLoRA hanya berisi selisih *weight* yang diperbarui, sehingga ukurannya jauh lebih kecil dibandingkan dengan model dasar Qwen 2.5 7B yang mencapai belasan gigabyte (Dettmers & May, 2023).

b) **Mekanisme Eksekusi (*Runtime Environment*)**

Model dijalankan di server inferensi mandiri berbasis Python Flask yang di-hosting di Google Colab. Saat inisialisasi layanan, server secara otomatis melakukan pengunduhan model dasar Qwen 2.5 7B dan menggabungkannya (*merging*) dengan adaptor QLoRA dari repositori hasil *Fine-tuning* sebelumnya. Mekanisme *dynamic loading* ini memungkinkan aplikasi berjalan pada infrastruktur GPU T4 dengan performa yang tinggi, karena beban komputasi sepenuhnya ditangani oleh server bukan oleh perangkat pengguna (Grinberg & O'Reilly, 2014). Hal ini juga memastikan bahwa kemampuan penalaran multibahasa Qwen 2.5 tetap optimal meskipun diakses melalui aplikasi mobile yang ringan.

2. ***Integrasi Sistem (System Integration)***

Tahap integrasi menitikberatkan pada konfigurasi lingkungan operasional untuk menjamin interoperabilitas antar-sistem. Mengingat arsitektur sistem

terdistribusi antara perangkat *mobile* (klien) dan *cloud server* (server), integrasi dilakukan melalui tiga mekanisme teknis utama:

a) **Manajemen Konfigurasi Dinamis (*Dynamic Configuration Management*)**

Mengingat server inferensi berjalan pada lingkungan ephemeral (Google Colab) dengan alamat *tunneling* (Ngrok) yang berubah setiap sesi, metode pengkodean URL statis (*hardcoding*) tidak dapat diterapkan. Sebagai solusi, diterapkan mekanisme konfigurasi jarak jauh (*remote configuration*) memanfaatkan layanan Firebase Firestore. Dalam arsitektur ini, Firestore berfungsi juga sebagai *Service Registry*. Setiap kali server backend diinisialisasi, server akan memutakhirkan alamat URL aktif ke dalam dokumen konfigurasi di database. Selanjutnya, pada saat aplikasi mobile dijalankan (*runtime*), aplikasi terlebih dahulu melakukan permintaan data (*fetch*) ke Firestore untuk mendapatkan URL dasar (*Base URL*) yang valid. Pendekatan ini memungkinkan pemutakhiran *endpoint* API secara *real-time* dan terpusat tanpa memerlukan modifikasi kode atau kompilasi ulang pada sisi aplikasi klien (Eisenman, 2017).

b) **Penanganan Akses Lintas Asal (*CORS Handling*)**

Untuk mengizinkan aplikasi *mobile* mengakses sumber daya pada server Flask yang berada di domain berbeda, diterapkan konfigurasi *Cross-Origin Resource Sharing* (CORS) pada sisi *backend*. Implementasi ini melibatkan pengaturan *header* HTTP yang mengizinkan metode POST dari *origin* manapun, hal ini memastikan lalu lintas data JSON antara aplikasi dan model AI tidak diblokir oleh kebijakan keamanan peramban atau jaringan (Grinberg & O'Reilly, 2014).

c) **Manajemen Latensi Jaringan (*Latency Management*)**

Mengingat proses generasi cerita oleh model LLM membutuhkan waktu komputasi yang bervariasi bisa 30-120 detik tergantung panjang cerita, maka integrasi protokol komunikasi disesuaikan untuk menangani koneksi jangka panjang. Konfigurasi *timeout* pada klien

HTTP aplikasi diperpanjang untuk mencegah pemutusan koneksi prematur (*request timeout*) sebelum server selesai mengirimkan seluruh teks cerita, agar pengguna mendapatkan pengalaman yang stabil meskipun terjadi latensi pemrosesan (Hillar, 2016).

3. Uji Coba Terbatas (*Alpha Testing*)

Sebelum didistribusikan kepada pengguna akhir, sistem menjalani uji coba internal atau *Alpha Testing* untuk memverifikasi fungsionalitas sistem secara menyeluruh (Sugiyono, 2013). Maka dalam penelitian ini, pengujian menerapkan metode Black-Box Testing, yaitu teknik pengujian perangkat lunak yang berfokus pada validasi fungsionalitas input-output aplikasi tanpa memeriksa struktur kode internalnya (Nidhra & Dondeti, 2012).

Prosedur pengujian dilakukan secara sistematis oleh peneliti menggunakan instrumen Lembar Kasus Uji (*Test Case*). Skenario pengujian dirancang untuk mencakup dua kondisi, yaitu input valid yaitu data sesuai format dan input invalid yaitu data tidak sesuai format atau kosong, guna menguji ketahanan sistem (*robustness*) (Sugiyono, 2013). Lingkup pengujian meliputi:.

- **Modul Autentikasi:** Menguji validasi format *email*, keamanan kata sandi, dan manajemen sesi pengguna di Firebase.
- **Modul Generasi AI:** Menguji respons aplikasi terhadap berbagai kombinasi pilihan input (tema dan moral), penanganan kesalahan (*error handling*) saat terjadi *timeout*, serta fitur penyuntingan (*editing*) cerita setelah generasi.
- **Modul Reading:** Menguji keterbacaan cerita pada halaman baca (*Reading Page*), responsivitas antarmuka, serta kelancaran navigasi antar halaman.

Hasil pengujian akan dicatat dalam tabel rekapitulasi "Diterima" (*Pass*) atau "Ditolak" (*Fail*). Jika ditemukan kesalahan (*bugs*), akan dilakukan perbaikan kode (*debugging*) dan pengujian ulang (*re-testing*) hingga seluruh fitur dinyatakan valid 100% sebelum memasuki tahap uji coba lapangan (*Beta Testing*). Rancangan tabel pengujian dapat dilihat pada **Tabel 3.4** berikut:

ID Uji	Fitur / Modul	Skenario Pengujian	Test Case (Input & Aksi)	Hasil yang Diharapkan
A. MODUL AUTENTIKASI (FIREBASE)				
TC-A-01	Registrasi & Login	Validasi format email tidak standar	Input email tanpa domain (contoh: user123) atau tanpa simbol @. Klik daftar/masuk.	Sistem menolak input dan menampilkan pesan error "Format email tidak valid".
TC-A-02	Manajemen Sesi	Persistensi sesi pengguna (<i>Auto-login</i>)	Login berhasil -> Tutup aplikasi sepenuhnya (<i>kill app</i>) -> Buka kembali aplikasi.	Pengguna langsung masuk ke halaman utama (<i>Dashboard</i>) tanpa diminta login ulang.
TC-A-03	Keamanan Akun	Penanganan kredensial salah	Input email terdaftar dengan password acak/salah.	Sistem menolak akses dan menampilkan pesan umum "Email atau kata sandi salah".
B. MODUL GENERASI AI (CORE SYSTEM & EDITING)				
TC-G-01	Input Validasi	Validasi kelengkapan pilihan (<i>Selection</i>)	Biarkan pilihan "Tema" atau "Moral" belum terpilih (<i>default state</i>), lalu tekan tombol "Buat Cerita".	Tombol "Buat Cerita" tetap disabled (abu-abu) atau muncul toast message "Harap pilih Tema dan Moral terlebih dahulu".
TC-G-02	Fungsionalitas Utama	Respons kombinasi pilihan (<i>Happy Path</i>)	Pilih Tema: "Petualangan", Pilih Moral: "Kerja Sama". Generate.	Sistem menghasilkan cerita yang relevan dengan petualangan dan kerja sama. Cerita

				tersimpan di database.
TC-G-03	Error Handling	Penanganan Server Timeout / Koneksi Putus	Matikan koneksi internet atau simulasikan latency tinggi saat proses loading AI.	Aplikasi tidak crash. Menampilkan pesan: "Gagal membuat cerita, periksa koneksi Anda" dan tombol Retry muncul.
TC-G-04	Fitur Editing	Penyuntingan Pasca-Generasi	Buat Cerita AI -> Edit bagian isi paragraf dan judul -> Simpan perubahan.	Perubahan tersimpan di database dan langsung terlihat saat masuk kembali ke mode baca (Reading Mode).
C. MODUL READING (POTRAIT & NAVIGATION)				
TC-R-01	Segmentasi Teks	Validasi Pemenggalan Kalimat per Slide	Buka cerita hasil generasi. Perhatikan muatan teks pada setiap <i>slide</i> halaman.	Setiap <i>slide</i> hanya memuat 1-2 kalimat utuh (tidak terpotong di tengah kata/huruf). Teks tampil rapi tanpa perlu <i>scroll</i> berlebihan.
TC-R-02	Navigasi Halaman	Perpindahan Slide (Next/Prev)	Klik tombol navigasi atau geser (<i>swipe</i>) ke halaman selanjutnya dan sebelumnya.	Transisi antar <i>slide</i> berjalan lancar. Urutan kalimat cerita bersambung logis dari slide A ke slide B.
TC-R-03	Stabilitas Layout	Konsistensi Tampilan	Coba putar HP ke posisi <i>Landscape</i> atau buka di HP	Tampilan tetap terkunci di mode <i>Portrait</i> . Posisi

		(Portrait Lock)	dengan rasio layar berbeda.	teks tetap di area baca yang nyaman (tidak tertutup tombol navigasi).
--	--	-----------------	-----------------------------	---

3.2.5 Tahap Evaluasi (Evaluation)

Fase evaluasi merupakan tahap penyempurnaan dalam kerangka model ADDIE yang terbagi menjadi dua dimensi pemantauan, yaitu evaluasi formatif dan evaluasi sumatif (Aldoobie, 2015). Dalam konteks pengembangan sistem Generative AI ini, evaluasi formatif telah diintegrasikan secara berkala selama fase pengembangan berlangsung, khususnya ketika proses debugging kode dan pengujian fungsionalitas sistem menggunakan metode *black-box testing*. Pengujian formatif tersebut berfungsi untuk menjamin seluruh komponen arsitektur, mulai dari API hingga antarmuka aplikasi, berjalan stabil secara teknis sebelum berinteraksi dengan pengguna nyata.

Setelah aplikasi dinyatakan lolos uji fungsional, sistem memasuki tahap evaluasi sumatif akhir. Mengingat kecerdasan buatan dalam aplikasi ini menghasilkan konten narasi cerita anak yang dinamis, maka validasi kelayakan tidak dapat hanya bergantung pada metrik mesin, melainkan mutlak membutuhkan penilaian manusia atau *human-in-the-loop* (Sumintono & Widhiarso, 2015) Oleh karena itu, evaluasi sumatif difokuskan pada dua mekanisme krusial:

1. Validasi Ahli (*Expert Judgment*): Mengukur validitas isi (*content validity*), keamanan moral, dan koherensi bahasa dari luaran cerita AI.
2. Uji Coba Pengguna (*User Testing*): Mengevaluasi tingkat ketergunaan (*usability*) aplikasi oleh orang tua menggunakan metode *System Usability Scale* atau SUS.

Adapun penjabaran yang lebih komprehensif mengenai siapa saja subjek yang terlibat, rancangan instrumen yang digunakan, prosedur pengumpulan data, hingga teknik analisis statistik untuk membuktikan validitas produk pada tahap evaluasi sumatif ini akan diuraikan secara khusus pada Sub-bab berikutnya.

3.3 Partisipan dan Subjek Penelitian

Pelaksanaan penelitian pengembangan (R&D) mengharuskan adanya evaluasi produk dari dua sudut pandang yang berbeda, yaitu evaluasi dari pakar untuk

memvalidasi kualitas teoretis produk, dan evaluasi dari pengguna untuk menilai kepraktisan operasional sistem (Sugiyono, 2013). Oleh karena itu, partisipan dalam penelitian ini secara definitif dibagi menjadi dua kelompok utama, yaitu para ahli (*expert judgment*) sebagai validator instrumen dan sistem, serta pengguna akhir (*end-user*) sebagai subjek uji coba lapangan.

3.3.1 Validasi Ahli (Expert Judgment)

Validasi ahli diperlukan untuk mengukur kualitas substansial dari cerita yang dihasilkan oleh Generative AI. Mengingat sistem ini ditujukan untuk anak usia dini sedangkan kecerdasan buatan memiliki kecenderungan bias atau halusinasi informasi (Gozalo-brizuela & Garrido-merch, 2023), maka evaluasi pakar diperlukan untuk memastikan keamanan nilai moral dan akurasi kebahasaan pada cerita yang dihasilkan.

Untuk mencapai tingkat kesepakatan (*inter-rater reliability*) yang objektif dalam perhitungan *Aiken's V*, instrumen disyaratkan untuk dinilai oleh minimal 3 (tiga) orang penilai (Retnawati, 2016). Berdasarkan pertimbangan kepraktisan dan relevansi lapangan, penelitian ini melibatkan praktisi pendidikan langsung, yaitu 2 (dua) orang Guru Pendidikan Anak Usia Dini (PAUD/TK) sebagai Ahli Materi, dan 1 (satu) orang Guru Bahasa Indonesia sebagai Ahli Bahasa.

Pemilihan praktisi pendidikan (guru) dibandingkan akademisi murni didasarkan pada pertimbangan bahwa guru merupakan pihak yang setiap hari berhadapan langsung dengan psikologi perkembangan anak, sehingga mereka paling memahami struktur bahasa dan muatan moral yang benar-benar dapat dicerna oleh anak usia 3-6 tahun. Rincian kepakaran dirangkum pada Tabel 3.5 berikut:

Tabel 3. 5 Kriteria, Peran, dan Kualifikasi Validator Ahli

Domain Keahlian	Jumlah Target	Kualifikasi Minimum (Kriteria Kelayakan)	Fokus Validasi Output AI
Ahli Materi (Pendidikan)	2 Orang	Guru atau Praktisi PAUD/TK yang memiliki pengalaman	Menilai kesesuaian nilai moral dengan perkembangan kognitif usia

Anak Usia Dini)		mengajar minimal 1 tahun.	3-6 tahun, dan memvalidasi keamanan konten (child safety) dari luaran AI.
Ahli Bahasa (Bahasa Indonesia)	1 Orang	Guru Bahasa Indonesia dengan pengalaman mengajar minimal 1 tahun.	Menilai aspek keterbacaan (readability), kesesuaian diksi untuk anak prasekolah, dan koherensi alur narasi yang dihasilkan AI.

Penetapan kriteria spesifik ini didasarkan pada prinsip validitas isi, yaitu kelayakan instrumen dan produk pendidikan mutlak harus dinilai oleh penilai yang memiliki kompetensi relevan pada bidangnya agar hasil evaluasi tidak bias (Sumintono & Widhiarso, 2015).

3.3.2 Subjek Penelitian (Pengguna Akhir)

Subjek penelitian pada tahap pengujian lapangan adalah orang tua (Ayah/Ibu) yang memiliki anak berusia 3 hingga 6 tahun (early childhood). Pemilihan orang tua sebagai responden utama dan bukan anak secara langsung didasarkan pada landasan teori perkembangan kognitif. Menurut tahap pra-operasional Piaget, anak usia prasekolah (3-6 tahun) belum memiliki kecakapan metakognitif dan kemampuan literasi yang memadai untuk merefleksikan pengalaman penggunaannya ke dalam bentuk instrumen kuesioner seperti *System Usability Scale* (SUS) secara mandiri (Richmond et al., 2016). Dalam penelitian aplikasi pengasuhan (*digital parenting*) ini, orang tua bertindak sebagai fasilitator utama (*gatekeeper*) yang mengoperasikan sistem generasi AI dan membacakannya untuk anak (Pariser, 2011). Oleh karena itu, persepsi orang tua terhadap kemudahan penggunaan (*usability*) merupakan data primer yang paling valid untuk mengevaluasi keberhasilan antarmuka aplikasi penelitian ini. Rentang usia anak 3-6 tahun dipilih secara spesifik karena fase ini diakui sebagai periode emas anak (*golden age*), yaitu kondisi ketika plastisitas otak anak berada pada puncaknya untuk menerima stimulus bahasa dan penanaman konsep moral (Gopnik, 2016).

3.3.3 Teknik Sampling (*Purposive Sampling*)

Mengingat populasi orang tua di Indonesia yang sangat luas, maka teknik pengambilan sampel yang digunakan untuk subjek pengguna akhir yaitu *Non-Probability Sampling* dengan pendekatan *Purposive Sampling*. *Purposive sampling* merupakan teknik penentuan sampel dengan pertimbangan atau kriteria tertentu, yang bertujuan untuk mendapatkan sumber data yang paling representatif dan memahami konteks penelitian (Sugiyono, 2013).

Terkait jumlah sampel uji coba (*sample size*), penelitian ini menargetkan pelibatan 10 hingga 15 responden orang tua. Penetapan rentang jumlah ini merujuk pada pedoman pengujian ketergunaan antarmuka (*usability testing*). Menurut model probabilitas penemuan kesalahan oleh Nielsen, pengujian yang melibatkan 5 pengguna telah mampu mengungkap sekitar 85% masalah pada antarmuka, sementara keterlibatan 10 hingga 15 pengguna dinilai sudah sangat mumpuni dan memiliki tingkat kepercayaan statistik yang tangguh (*robust*) untuk menghasilkan skor pengujian *System Usability Scale* (SUS) yang andal (Sauro, 2011). Proses penyaringan (*filtering*) subjek dilakukan berdasarkan kriteria inklusi berikut:

1. Kesesuaian Demografi: Orang tua (Ayah atau Ibu) yang memiliki anak kandung berusia 3–6 tahun.
2. Kesiapan Infrastruktur: Memiliki *smartphone* berbasis Android dengan spesifikasi minimum yang mendukung aplikasi (minimal Android 10).
3. Literasi Digital: Mampu mengoperasikan aplikasi *mobile* dasar dan memahami instruksi pengisian kuesioner digital.

Dengan penerapan kriteria *purposive* ini, data *usability* yang diperoleh dapat dijamin murni berasal dari target audiens yang tepat, sehingga hasil evaluasi aplikasi penelitian ini benar-benar mencerminkan pengalaman pengguna di lingkungan pengasuhan dunia nyata (Brooke, 2020).

3.4 Instrumen Penelitian

Instrumen penelitian memegang peranan vital sebagai alat ukur untuk mengumpulkan data yang valid dan reliabel, serta menjadi landasan objektivitas hasil penelitian (Sugiyono, 2013). Mengingat penelitian ini berfokus pada pengembangan sistem cerdas berbasis *Generative AI*, instrumen penelitian yang digunakan terbagi menjadi dua jenis spesifik sesuai dengan objek yang dinilai:

Instrumen Simulasi Digital untuk validasi ahli terhadap kualitas konten cerita AI, dan Kuesioner SUS untuk menilai interaksi pengguna terhadap antarmuka aplikasi.

3.4.1 Instrumen Validasi Ahli (*Web-Based Simulation*)

Berbeda dengan validasi konvensional yang menggunakan lembar periksa manual, pada penelitian ini mengembangkan instrumen validasi berbasis Simulasi Web (*Web-Based Simulation*). Pendekatan ini dipilih untuk memastikan proses penilaian dilakukan secara kontekstual. Ahli tidak hanya menilai teks cerita mentah, tetapi juga memvalidasi aspek teknis penyajian, seperti ketepatan pemenggalan kata (*word segmentation*) pada setiap slide dan aliran navigasi cerita.

Menurut pedoman evaluasi Human-AI Interaction, validasi luaran AI harus dilakukan dalam konteks antarmuka pengguna yang sebenarnya untuk meminimalkan bias interpretasi (Amershi et al., 2019). Dalam simulasi ini, para ahli akan disajikan 15 sampel cerita yang dihasilkan secara acak oleh sistem. Jumlah sampel ini ditetapkan untuk mencapai titik jenuh data (*data saturation*), yaitu variasi pola kesalahan AI sudah dapat teridentifikasi secara komprehensif tanpa perlu menguji seluruh kemungkinan kombinasi (Guest, Bunce, & Johnson, 2006).

Instrumen penilaian terdiri dari 8 butir indikator yang disusun menggunakan penilaian Skala Likert 1-5 (1 = Sangat Kurang, 5 = Sangat Baik). Kisi-kisi instrumen disusun berdasarkan standar perkembangan literasi anak usia dini dan prinsip keamanan konten digital.

Tabel 3. 6 Kisi-Kisi Instrumen Validasi Ahli (Simulasi Digital)

Kode	Aspek Penilaian	Indikator Evaluasi	Referensi Dasar
I1	Moral	Nilai moral tersampaikan melalui tindakan konkret tokoh, bukan narasi yang bersifat menggurui (ceramah).	(Latifah, Munajah, & Hasanah, 2021)
I2	Moral	Pesan moral tetap fokus dan konsisten (tidak melenceng) dari awal hingga akhir cerita.	(Vitz, 1990)

I3	Narasi	Alur cerita memiliki struktur logis yang utuh (Pengenalan - Konflik - Penyelesaian).	(Pusat Perbukuan, 2022)
I4	Narasi	Penyelesaian masalah (<i>resolusi</i>) bersifat tuntas, masuk akal, dan memberikan rasa puas.	(Pusat Perbukuan, 2022)
I5	Narasi	Cerita memiliki daya tarik imajinatif yang mampu memancing antusiasme anak.	(Badan Bahasa, 2021)
I6	Bahasa	Diksi (pilihan kata) sederhana, konkret, dan sesuai kognitif anak usia 3-6 tahun.	(Pusat Perbukuan, 2022)
I7	Bahasa	Struktur kalimat mengalir alami (<i>natural</i>) dan bebas dari kekakuan bahasa mesin/terjemahan.	(Yang et al., 2025)
I8	Keamanan	Konten aman, bebas dari unsur kekerasan, stereotip negatif, atau hal yang menakutkan.	(United Nations International Children's Emergency Fund (UNICEF), 2021)

3.4.2 Kuesioner Ketergunaan (Usability)

Untuk mengevaluasi aspek interaksi pengguna (*User Experience*) pada aplikasi mobile, penelitian ini menggunakan instrumen baku *System Usability Scale* (SUS) yang didistribusikan melalui *platform* Google Forms. SUS dipilih karena telah terbukti secara empiris memiliki tingkat validitas dan reliabilitas yang tinggi ($r = 0.91$), bahkan ketika diujikan pada ukuran sampel yang kecil (Aaron Bangor, Kortum, & Miller, 2008; Sauro, 2011). Instrumen ini terdiri dari 10 pernyataan (5 pernyataan positif dan 5 pernyataan negatif) dengan skala Likert 1 hingga 5 (Sangat Tidak Setuju – Sangat Setuju) seperti dijabarkan pada tabel 2.8. Format ini

dirancang untuk mendeteksi inkonsistensi jawaban responden dan bias persetujuan (*acquiescence bias*) (Brooke, 2020).

3.5 Teknik Pengumpulan Data

Teknik pengumpulan data dilakukan secara komprehensif menggunakan pendekatan *mixed-method* yaitu teknis dan humanis untuk memastikan performa model AI dan kelayakan aplikasi memenuhi standar. Prosedur pengumpulan data dibagi menjadi tiga mekanisme utama: Telemetri sistem untuk data teknis, Simulasi berbasis web untuk validasi ahli, dan Uji coba berbasis tugas (*task-based*) untuk pengguna akhir.

3.5.1 Observasi Log Sistem (*System Telemetry*)

Pengumpulan data pada fase pelatihan model (*fine-tuning*) dilakukan secara otomatis menggunakan teknik observasi log sistem. Tujuannya yaitu untuk memantau stabilitas dan konvergensi model AI selama proses pembelajaran data teks cerita. Data metrik evaluasi teknis, seperti *training loss* dan *validation loss*, dicatat secara *real-time* menggunakan platform pelacakan eksperimen *Weights & Biases* (Biewald, 2020). Penggunaan instrumen pelacakan seperti WandB sangat esensial dalam pengembangan *Machine Learning* karena peneliti dapat merekam, memvisualisasikan, dan membandingkan setiap iterasi (*epoch*) parameter secara terpusat dan akurat, sehingga terhindar dari bias pelaporan manual. Data log ini nantinya menjadi bukti empiris bahwa model bahasa yang dikembangkan telah mencapai tingkat performa teknis yang stabil sebelum diintegrasikan ke dalam aplikasi *mobile*.

3.5.2 Simulasi Validasi Ahli (*Web-Based Simulation*)

Berbeda dengan metode konvensional yang menggunakan berkas dokumen fisik dan statis, pada penelitian ini pengumpulan data dari para ahli dilakukan melalui Website Simulator khusus. Teknik ini dipilih agar ahli dapat menilai output cerita dalam konteks lingkungan yang mendekati pengalaman pengguna, termasuk aspek pemenggalan kalimat (*segmentation*) dan alur navigasi per halaman.

Prosedur pengambilan data ahli dilakukan dengan langkah-langkah berikut:

1. **Akses Simulator:** Validator mengakses URL khusus yang berisi 15 sampel cerita hasil generasi AI (dengan variasi 3 cerita pernilai moral berbeda).

2. **Simulasi Baca:** Validator membaca cerita melalui antarmuka simulasi yang meniru tampilan layar HP (mode *portrait*), lengkap dengan fitur *slider* halaman dan pemenggalan kalimat.
3. **Penilaian Langsung:** Setelah membaca satu cerita, validator mengisi skor pada instrumen digital yang terintegrasi pada akhir slide setiap cerita.

Pendekatan ini menjamin *ecological validity* (validitas lingkungan), yaitu penilaian ahli didasarkan pada pengalaman interaksi nyata, bukan sekadar teks mentah (Amershi et al., 2019).

3.5.3 Angket atau Kuesioner (*Questionnaire*)

Pengumpulan data ketergunaan (*usability*) dari responden orang tua dilakukan menggunakan teknik Uji Coba Berbasis Tugas (*Task-Based Usability Testing*). Teknik ini mengharuskan pengguna untuk menyelesaikan serangkaian skenario tugas spesifik sebelum mengisi kuesioner, guna memastikan penilaian SUS mereka objektif dan berbasis pengalaman nyata (Rubin & Chisnell, 2008). Data dikumpulkan melalui Google Forms setelah responden menyelesaikan Skenario Tugas berikut pada aplikasi:

Tabel 3. 7 Matriks Ringkasan Pengumpulan Data

No	Kode Tugas	Deskripsi Aktivitas	Tujuan Observasi
1.	T1 - Onboarding	Pengguna melakukan instalasi aplikasi, membuka aplikasi, dan mendaftarkan akun baru (<i>Sign Up</i>).	Menguji kemudahan akses awal dan manajemen sesi.
2.	T2 - Creation	Pengguna memilih kombinasi "Tema" dan "Nilai Moral", lalu menekan tombol "Buat Cerita".	Menguji responsivitas fitur inti Generative AI.
3.	T3 - Reading	Pengguna membaca cerita yang dihasilkan minimal sampai 3 halaman, lalu mencoba fitur navigasi (Lanjut/Kembali).	Menguji kenyamanan antarmuka baca (<i>Reading Mode</i>).

Setelah ketiga tugas di atas selesai, responden diarahkan untuk mengisi kuesioner *System Usability Scale* (SUS) yang terdiri dari 10 pertanyaan persepsi.

Pemisahan antara fase "mencoba" dan fase "menilai" ini krusial untuk meminimalkan bias persepsi pengguna (Sauro, 2011).

3.6 Teknik Analisis Data

Data yang terkumpul dari instrumen penelitian selanjutnya diolah menggunakan teknik analisis statistik untuk menarik kesimpulan yang objektif. Analisis data dibagi menjadi tiga tahapan yang komprehensif.

3.6.1 Analisis Validitas Konten (Aiken's V)

Untuk mengukur tingkat kesepakatan antar validator (inter-rater agreement) terhadap kualitas cerita AI, penelitian ini menggunakan formula Aiken's V. Formula ini lebih kuat dibandingkan persentase deskriptif biasa karena memperhitungkan jumlah validator dan rentang skala penilaian, sehingga menghasilkan indeks validitas yang lebih presisi (Retnawati, 2016).

Rumus Aiken's V:

$$V = \frac{\sum s}{n(c - 1)}$$

Keterangan:

V = Indeks kesepakatan validator (rentang 0.0 - 1.0)

$$s = r - l_0$$

r = Skor yang diberikan oleh validator

l_0 = Skor terendah dalam skala penilaian (yaitu 1)

n = Jumlah validator ahli

c = Banyaknya kategori penilaian (yaitu 5)

Kriteria kelayakan didasarkan pada nilai V . Instrumen atau output dinyatakan valid dan dapat diterima jika nilai $V \geq 60$ (Retnawati, 2016).

3.6.2 Analisis Rasch Model (Objektivitas Data)

Data hasil penilaian ahli dan pengguna pada dasarnya bersifat ordinal (berjenjang tanpa jarak pasti). Menggunakan rata-rata hitung pada data ordinal dapat menimbulkan bias analisis. Oleh karena itu, penelitian ini menerapkan Pemodelan Rasch (Rasch Model) menggunakan perangkat lunak Winsteps untuk mengonversi data ordinal menjadi data berinterval sama (logit) (Boone & Staver, 2020).

Pemodelan Rasch memberikan estimasi presisi tinggi terkait sejauh mana kualitas instrumen dan objektivitas penilai. Menurut Sumintono dan Widhiarso (2015), keandalan data (fit data) dapat dievaluasi melalui parameter Mean Square (MNSQ). Berdasarkan standar Linacre (2002), data dianggap fit (layak dan tidak ada miskonsepsi penilaian) jika nilai Outfit MNSQ berada pada rentang 0.5 hingga 1.5. Data yang berada di luar rentang tersebut mengindikasikan adanya penilaian yang outlier atau tidak konsisten dari responden.

3.6.3 Analisis Ketergunaan (Skor SUS)

Data kuesioner SUS dari orang tua dianalisis menggunakan aturan perhitungan standar untuk mendapatkan skor global *usability*. Setiap item memiliki bobot skor kontribusi antara 0 hingga 4 dengan aturan sebagai berikut:

1. Pernyataan Positif (Item Ganjil): Skor responden dikurangi 1 (Skor - 1).
2. Pernyataan Negatif (Item Genap): Nilai 5 dikurangi skor responden (5 - Skor).

Total skor kontribusi dari ke-10 item kemudian dikalikan dengan konstanta 2,5 untuk menghasilkan skor akhir skala 0 hingga 100:

$$Skor\ SUS = \left(\sum Skor\ Kontribusi \right) \times 2.5$$

Skor akhir rata-rata dari seluruh responden kemudian diinterpretasikan berdasarkan pedoman pengelompokan tingkat penerimaan. Menurut Bangor et al. (2009), skor SUS memiliki parameter kualitatif yang menentukan tingkat kelayakan sebuah antarmuka.

Gambar 3.1 Interpretasi Skor SUS (Bangor et al., 2009)

(Silakan sisipkan gambar standar penggaris SUS Bangor di sini yang memuat rentang Acceptability, Grade Scale, dan Adjective Rating)

Secara spesifik, aplikasi dinyatakan dapat diterima (*Acceptable*) dan dikategorikan "Baik" (*Good*) jika skor rata-rata SUS mencapai angka **di atas 68** (Bangor et al., 2009). Jika skor berada di bawah angka tersebut, berarti diperlukan evaluasi dan perbaikan ulang pada antarmuka aplikasi.

DAFTAR PUSTAKA

- Ainslie, J., Lee-Thorp, J., de Jong, M., Zemlyanskiy, Y., Lebrón, F., & Sanghai, S. (2023). GQA: Training Generalized Multi-Query Transformer Models from Multi-Head Checkpoints. *EMNLP 2023 - 2023 Conference on Empirical Methods in Natural Language Processing, Proceedings*, 4895–4901. <https://doi.org/10.18653/v1/2023.emnlp-main.298>
- Aldoobie, N. (2015). ADDIE Model. *American International Journal of Contemporary Research*, 107(3), 361–373.
- Amershi, S., Weld, D., Vorvoreanu, M., Fourney, A., Nushi, B., Collisson, P., ... Horvitz, E. (2019). Guidelines for Human-AI Interaction. *CHI Conference on Human Factors in Computing Systems Proceedings*.
- Avinash Navlani, Armando Fandango, and I. I. (2021). *Python Data Analysis. Journal of Chemical Information and Modeling* (Vol. 53).
- Badan Bahasa. (2021). Penyediaan Buku Bacaan Literasi Seleksi Penulis Buku Bacaan Literasi 2021.
- Bai, J., Bai, S., Chu, Y., Cui, Z., Dang, K., Deng, X., ... Zhu, T. (2023). Qwen Technical Report. Retrieved from <http://arxiv.org/abs/2309.16609>
- Bangor, A., Kortum, P., & Miller, J. (2009). Determining what individual SUS scores mean; adding an adjective rating. *Journal of Usability Studies*, 4(3), 114–123.
- Bangor, Aaron, Kortum, P. T., & Miller, J. T. (2008). An empirical evaluation of the system usability scale. *International Journal of Human-Computer Interaction*, 24(6), 574–594. <https://doi.org/10.1080/10447310802205776>
- Biewald, L. (2020). Experiment tracking with weights and biases. Retrieved February 2, 2026, from <https://www.wandb.com/>
- Boone, W. J., & Staver, J. R. (2020a). Correction to: *Advances in Rasch Analyses in the Human Sciences*. *Advances in Rasch Analyses in the Human Sciences*. https://doi.org/10.1007/978-3-030-43420-5_21
- Boone, W. J., & Staver, J. R. (2020b). Correction to: *Advances in Rasch Analyses in the Human Sciences*. *Advances in Rasch Analyses in the Human Sciences*, C1–C2. https://doi.org/10.1007/978-3-030-43420-5_21
- Brooke, J. (2020). SUS: A “Quick and Dirty” Usability Scale. *Usability Evaluation In Industry*, 207–212. <https://doi.org/10.1201/9781498710411-35>
- Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., ... Amodei, D. (2020). Language models are few-shot learners. *Advances in Neural Information Processing Systems, 2020-Decem*.
- Chatzimpampas, A., Bibi, S., Zozas, I., & Kerren, A. (2019). Analyzing the evolution of JavaScript applications. *ENASE 2019 - Proceedings of the 14th International Conference on Evaluation of Novel Approaches to Software Engineering*, (Enase), 359–366. <https://doi.org/10.5220/0007727603590366>
- Chen, J. (2025). Enjoyment of AI-generated stories blending art and science: impact on preschoolers’ pro-environmental attitudes. *Frontiers in Psychology*,

16(July), 1–13. <https://doi.org/10.3389/fpsyg.2025.1579510>

- Childbook.ai. (2023). Childbook: Personalized children's books with AI.
- Coyne, S. M., Linder, J. R., Rasmussen, E. E., Nelson, D. A., & Birkbeck, V. (2016). Pretty as a Princess : Longitudinal Effects of Engagement With Disney Princesses on Gender Stereotypes , Body Esteem , and Prosocial Behavior in Children, *00(0)*, 1–17. <https://doi.org/10.1111/cdev.12569>
- Craig, S. D. (2009). AIED 2009 : 14 th International Conference on Artificial Intelligence in Education.
- Dettmers, T., & May, L. G. (2023). QL O RA : Efficient Finetuning of Quantized LLMs.
- Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. *NAACL HLT 2019 - 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies - Proceedings of the Conference, 1(Mlm)*, 4171–4186.
- Eisenman, B. (2017). *Learning React Native, 2nd Edition*. Retrieved from <https://books.google.pt/books?id=BJH0swEACAAJ>
- Evi Chamalah, Azizah, A., Wulandari, Y., & Wardani, O. P. (2025). Artificial intelligence media-assisted storytelling therapy as a solution for handling speech delay in early childhood. *Bahastra*, *45(1)*, 166–174. <https://doi.org/10.26555/bs.v45i1.1245>
- Expo. (2026). Expo Documentation. Retrieved February 6, 2026, from <https://docs.expo.dev/>
- Friska, Y. (2025). YouTube Kids on Children ' s English Communication Skills : Parents ' Beliefs and Attitudes, *10(2)*, 441–452.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. *Prmu*, 1–10. Retrieved from www.deeplearningbook.org
- Google Developers. (2026). Firebase Realtime Database Documentation. Retrieved February 10, 2026, from <https://firebase.google.com/docs/database>
- Gopnik, A. (2016). The Gardener And The Carpenter: What The New Science of Child Development Tells Us About The Relationship Between Parents and Children.
- Goyal, P., Dollár, P., Girshick, R., Noordhuis, P., Wesolowski, L., Kyrola, A., ... He, K. (2018). Accurate, Large Minibatch SGD: Training ImageNet in 1 Hour. Retrieved from <http://arxiv.org/abs/1706.02677>
- Gozalo-brizuela, R., & Garrido-merch, E. C. (2023). A survey of Generative AI Applications.
- Grinberg, M., & O'Reilly. (2014). *Flask Web Development. Flask Web Development*.
- Guest, G., Bunce, A., & Johnson, L. (2006). How Many Interviews Are Enough?: An Experiment with Data Saturation and Variability. *Field Methods*, *18(1)*, 59–82. <https://doi.org/10.1177/1525822X05279903>

- Han, D., & Han, M. (2023). Unsloth: Faster and Memory-Efficient LLM Fine-tuning. GitHub. Retrieved from <https://github.com/unslothai/unsloth>
- Haverbeke, M. (2007). *Eloquent JavaScript. International immunology* (Vol. 24). <https://doi.org/10.1190/1.9781560801597.index>
- Hillar, G. C. (2016). *Building RESTful Python Web Services* (Vol. 32). Packt Publishing.
- Howard, J., & Ruder, S. (2018). Universal language model fine-tuning for text classification. *ACL 2018 - 56th Annual Meeting of the Association for Computational Linguistics, Proceedings of the Conference (Long Papers)*, 1, 328–339. <https://doi.org/10.18653/v1/p18-1031>
- ISO/IEC 25010. (2011). ISO/IEC Systems and Software Engineering — Requirements and Evaluation. *International Organization for Standardization (ISO) and IEC, 2011*.
- Joshi, A., Kale, S., Chandel, S., & Pal, D. (2015). Likert Scale: Explored and Explained. *British Journal of Applied Science & Technology*, 7(4), 396–403. <https://doi.org/10.9734/bjast/2015/14975>
- Kirkpatrick, J., Pascanu, R., Rabinowitz, N., Veness, J., Desjardins, G., Rusu, A. A., ... Hadsell, R. (2017). Overcoming catastrophic forgetting in neural networks. *Proceedings of the National Academy of Sciences of the United States of America*, 114(13), 3521–3526. <https://doi.org/10.1073/pnas.1611835114>
- Latifah, N., Munajah, R., & Hasanah, U. (2021). *Pengantar Sastra Anak*. Universitas Trilogi.
- Likert, R. (1932). “Technique for the Measurement of Attitudes, A.” *New York University*. <https://doi.org/10.4135/9781412961288.n454>
- Linacre, J. M. (2002). What do Infit and Outfit, Mean-square and Standardized mean? Retrieved February 3, 2026, from <https://www.rasch.org/rmt/rmt162f.htm>
- Livingstone, S., & Mascheroni, G. (2018). European research on children ’ s internet use : assessing the past and anticipating the future. <https://doi.org/10.1177/1461444816685930>
- Makridis, G., Oikonomou, A., & Koukos, V. (2024). FairyLandAI: Personalized Fairy Tales utilizing ChatGPT and DALL-E-3.
- Mascheroni, E. G., & Holloway, D. (2017). The Internet of Toys : A Report on Media and Social Discourses around Young Children and IoToys. *DigiLitEY*.
- Mcdaniel, B. T., Radesky, J. S., & Sciences, C. (2019). Technoference: Parent Distraction with Technology and Associations with Child Behavior Problems. *HHS Public Access*, 89(1), 100–109. <https://doi.org/10.1111/cdev.12822.Technoference>
- Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). Efficient estimation of word representations in vector space. *1st International Conference on Learning Representations, ICLR 2013 - Workshop Track Proceedings*, 1–12.
- Müller, M. (2025). Leveraging Python in AI and Machine Learning: A Survey of

- Techniques and Educational Approaches in Software Engineering. *International Journal of Engineering and Information Systems*, 9(1), 55–58. Retrieved from <https://www.researchgate.net/publication/388852036>
- Nesbit, J. C., Belfer, K., & Leacock, T. L. (2004). LORI 1.5: Learning object review instrument. Retrieved July, 26, 2006.
- Nguyen, H. V., Park, H., Yoo, N., & Yang, J. (2025). Resource-efficient fine-tuning of large vision-language models for multimodal perception in autonomous excavators. *Frontiers in Artificial Intelligence*, 8(November), 1–24. <https://doi.org/10.3389/frai.2025.1681277>
- Nichols, S. (2022). Digitally Mediated Parenting : A Review of the Literature.
- Nidhra, S., & Dondeti, J. (2012). BLACK BOX AND WHITE BOX TESTING TECHNIQUES – A LITERATURE REVIEW. *International Journal of Embedded Systems and Applications (IJESA)*, 2(2), 29–50. <https://doi.org/10.5121/ijesa.2012.2204>
- Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C. L., Mishkin, P., ... Lowe, R. (2022). Training language models to follow instructions with human feedback. *Advances in Neural Information Processing Systems*, 35.
- Pariser, E. (2011). The Filter Bubble: What the Internet is Hiding from You.
- Pusat Perbukuan. (2022). Pedoman Perjenjangan Buku. *Kementerian Pendidikan, Kebudayaan, Riset, Dan Teknologi*, (021), 1–45.
- Qwen, T. (2025). Qwen2.5 Technical Report, 1–26.
- Retnawati, H. (2016). *Heri Retnawati 9 786021 547984*.
- Richmond, J. B., Health, C., Bunge, S. A., Ph, D., Johnson, R. W., & Gates, M. (2016). From Best Practices to Breakthrough Impacts NATIONAL SCIENTIFIC COUNCIL ON THE DEVELOPING CHILD Foundation.
- Rompis, A. C., & Aji, R. F. (2018). Perbandingan Performa Kinerja Node.js, PHP, dan Python dalam Aplikasi REST Performance Comparison of Node.js, PHP, and Python Performance. *Cogito Smart Journal*, 4(1), 171–187.
- Rubin, J., & Chisnell, D. (2008). Handbook of Usability Testing How to Plan, Design, and Conduct Effective Tests. Retrieved from <http://scholar.google.com/scholar?hl=en&btnG=Search&q=intitle:Handbook+of+Usability+Testing#3>
- Russell, S., & Norvig, P. (2021). *Artificial Intelligence: A Modern Approach, Global Edition, 4ed*.
- Sauro, J. (2011). Measuring Usability with the System Usability Scale (SUS). Retrieved February 2, 2026, from <https://measuringu.com/sus/>
- StoryBee. (2024). StoryBee: Turn your voice into stories.
- Storywizard.ai. (2023). Storywizard: AI-powered story generator for children.
- Sugiyono. (2013). *Metode Penelitian Kuantitatif, Kualitatif dan R&D. Bandung:Alfabeta*. Bandung: Alfabeta.
- Sumintono, B., & Widhiarso, W. (2015). Penilaian Pendidikan dan Ujian. *Aplikasi RascH Pemodelan Pada Assessment Pendidikan*, (September), 1–24.

- Turney, P. D., & Pantel, P. (2010). From frequency to meaning: Vector space models of semantics. *Journal of Artificial Intelligence Research*, 37, 141–188. <https://doi.org/10.1613/jair.2934>
- United Nations International Children's Emergency Fund (UNICEF). (2021). Policy guidance on AI for children 2.0 | NOVEMBER 2021. Retrieved from <https://www.unicef.org/innocenti/media/1341/file/UNICEF-Global-Insight-policy-guidance-AI-children-2.0-2021.pdf>
- Vaswani, A. (2017). Attention Is All You Need, (Nips).
- Vitz, P. C. (1990). The use of stories in moral development: New psychological reasons for an old education method. *American Psychologist*.
- Wang, J., Yang, J., Tu, J., Zhang, J., Ma, J., Yang, J., ... Zhang, Z. (2024). QWEN2 TECHNICAL REPORT. *ArXiv Preprint*, 1–26.
- Wei, J., Bosma, M., Zhao, V. Y., Guu, K., Yu, A. W., Lester, B., ... Le, Q. V. (2022). Finetuned Language Models Are Zero-Shot Learners. *ICLR 2022 - 10th International Conference on Learning Representations*, 1–46.
- Yang, A., Yang, B., Hui, B., Zheng, B., Yu, B., Zhou, C., ... Fan, Z. (2024). Qwen2 Technical Report, 1–26. Retrieved from <http://arxiv.org/abs/2407.10671>
- Yang, A., Yang, B., Zhang, B., Hui, B., Zheng, B., Yu, B., ... Qiu, Z. (2025). Qwen2.5 Technical Report, 1–26. Retrieved from <http://arxiv.org/abs/2412.15115>
- Yasaroglu, C., & Boylu, M. A. (2020). Youtubers' Effect on Children's Values : Parents' Views, 7(4), 1–15. <https://doi.org/10.19044/ejes.v7no4a1>
- Zarichuk, O. (2023). Comparative analysis of frameworks for mobile application development: Native, hybrid, or cross-platform solutions. *Вісник Черкаського Державного Технологічного Університету*, 28(4), 19–27. <https://doi.org/10.62660/2306-4412.4.2023.19-27>
- Zhao, W. X., Mao, Y., Ge, Y., Fan, Y., Xu, W., Mi, Y., ... Gao, Y. (2025). A survey on LoRA of large language models. *Frontiers of Computer Science*, 19(7), 1–144. <https://doi.org/10.1007/s11704-024-40663-9>
- Zhou, C., Liu, P., Xu, P., Iyer, S., Sun, J., Mao, Y., ... Levy, O. (2023). LIMA: Less Is More for Alignment. *Advances in Neural Information Processing Systems*, 36, 1–15.